Technische Universität Berlin



Advanced Projects at the QU Lab 2026

Quality & Usability Lab

Neha Deshpande, M.Sc. n.deshpande@tu-berlin.de

Creative Commons (CC) 2018 Michael Wagner

Overview

Technische Universität Berlin

Title: Robustness and Reliability of LLM-as-a-Judge Systems

Module: *Studienprojekt Quality & Usability (6LP)*

Language: *English*

Weekly update meeting: *Every Wednesday at 14:00 (except for two Wednesdays)*

Location: *In person (MAR 2.053), or Online via Zoom*

Quality & Usability Lab

Motivation & Problem Statement

Technische Universität Berlin

We already know, LLMs are currently used for…

- Translation
- Summarization
- Paraphrasing
- Grammar check

But nowadays, LLMs are also used for …

- **<u>Evaluating LLM outputs → LLM-as-a-judge</u>**

Quality & Usability Lab

Why LLM-as-a-Judge?

- Scalable alternative to human evaluation
- Faster and cheaper
- Captures semantic quality (not just word overlap)
- Works without reference or gold standard
- Flexible → multi-dimensional evaluation

Example

Berlin plant Ausbau des Fahrradwegenetzes

Die Berliner Senatsverwaltung für Verkehr hat angekündigt, das Fahrradwegenetz der Hauptstadt in den kommenden zwei Jahren deutlich auszubauen. Bis Ende 2028 sollen insgesamt 50 Kilometer neue, geschützte Radwege entstehen. Für das Projekt stellt die Stadt rund 25 Millionen Euro bereit.

Der Ausbau konzentriert sich zunächst auf die Bezirke Mitte, Friedrichshain-Kreuzberg und Neukölln. Ziel der Maßnahmen ist es, die Verkehrssicherheit für Radfahrerinnen und Radfahrer zu verbessern und den Autoverkehr langfristig zu reduzieren. Nach Angaben der Senatsverwaltung sollen die ersten Bauarbeiten im Frühjahr 2027 beginnen.

Während Umweltverbände die Pläne begrüßen, äußern einige Geschäftsleute Bedenken hinsichtlich des Wegfalls von Parkplätzen.

Summary A :

Die Berliner Senatsverwaltung plant den Bau von 50 Kilometern neuen geschützten Radwegen bis Ende 2028. Dafür stehen 25 Millionen Euro zur Verfügung. Der Ausbau betrifft Mitte, Friedrichshain-Kreuzberg und Neukölln. Die Bauarbeiten beginnen im Frühjahr 2027. Umweltverbände begrüßen die Pläne, während einige Geschäftsleute den Verlust von Parkplätzen kritisieren.

Factually correct and complete information

Summary B:

Die Berliner Senatsverwaltung plant den Bau von 50 Kilometern neuen geschützten Radwegen bis Ende 2028. Ziel des Projekts ist es, die Verkehrssicherheit für Radfahrerinnen und Radfahrer zu verbessern.

Factually correct but it is missing important information

Example

Berlin plant Ausbau des Fahrradwegenetzes

Die Berliner Senatsverwaltung für Verkehr hat angekündigt, das Fahrradwegenetz der Hauptstadt in den kommenden zwei Jahren deutlich auszubauen. Bis Ende 2028 sollen insgesamt 50 Kilometer neue, geschützte Radwege entstehen. Für das Projekt stellt die Stadt rund 25 Millionen Euro bereit.

Der Ausbau konzentriert sich zunächst auf die Bezirke Mitte, Friedrichshain-Kreuzberg und Neukölln. Ziel der Maßnahmen ist es, die Verkehrssicherheit für Radfahrerinnen und Radfahrer zu verbessern und den Autoverkehr langfristig zu reduzieren. Nach Angaben der Senatsverwaltung sollen die ersten Bauarbeiten im Frühjahr 2027 beginnen.

Während Umweltverbände die Pläne begrüßen, äußern einige Geschäftsleute Bedenken hinsichtlich des Wegfalls von Parkplätzen.

Summary A :

Die Berliner Senatsverwaltung plant den Bau von 50 Kilometern Die Berliner Senatsverwaltung plant den Bau von 50 Kilometern neuen geschützten Radwegen bis Ende 2028. Ziel des Projekts ist es, die Verkehrssicherheit für Radfahrerinnen und Radfahrer zu verbessern.

Factually correct and missing information

Faithfulness 7/7,
Coverage 4/7

Summary B:

Die Berliner Senatsverwaltung plant den Bau von 50 Kilometern neuen geschützten Radwegen bis Ende 2028. Dafür stehen 25 Millionen Euro zur Verfügung. Der Ausbau betrifft Mitte, Friedrichshain-Kreuzberg und Neukölln. Die Bauarbeiten beginnen im Frühjahr 2027. Umweltverbände begrüßen die Pläne, während einige Geschäftsleute den Verlust von Parkplätzen kritisieren.

Preferred: Factually correct and complete information

Faithfulness 7/7,
Coverage 6/7

- Gradually adding different factual errors
- Step 1: adding an “Entity Error”
    - Neukölln → Charlottenburg
    - Location changed
    - Should be penalized severity as it spreads misinformation
- Result on next slide →

Example

Berlin plant Ausbau des Fahrradwegenetzes

Die Berliner Senatsverwaltung für Verkehr hat angekündigt, das Fahrradwegenetz der Hauptstadt in den kommenden zwei Jahren deutlich auszubauen. Bis Ende 2028 sollen insgesamt 50 Kilometer neue, geschützte Radwege entstehen. Für das Projekt stellt die Stadt rund 25 Millionen Euro bereit.

Der Ausbau konzentriert sich zunächst auf die Bezirke Mitte, Friedrichshain-Kreuzberg und Neukölln. Ziel der Maßnahmen ist es, die Verkehrssicherheit für Radfahrerinnen und Radfahrer zu verbessern und den Autoverkehr langfristig zu reduzieren. Nach Angaben der Senatsverwaltung sollen die ersten Bauarbeiten im Frühjahr 2027 beginnen.

Während Umweltverbände die Pläne begrüßen, äußern einige Geschäftsleute Bedenken hinsichtlich des Wegfalls von Parkplätzen.

Summary A :

Die Berliner Senatsverwaltung plant den Bau von 50 Kilometern Die Berliner Senatsverwaltung plant den Bau von 50 Kilometern neuen geschützten Radwegen bis Ende 2028. Ziel des Projekts ist es, die Verkehrssicherheit für Radfahrerinnen und Radfahrer zu verbessern.

Factually correct and missing information

Faithfulness 7/7,
Coverage 4/7

Summary B:

Die Berliner Senatsverwaltung plant den Bau von 50 Kilometern neuen geschützten Radwegen bis Ende 2028. Dafür stehen 25 Millionen Euro zur Verfügung. Der Ausbau betrifft Mitte, Friedrichshain-Kreuzberg und **Charlottenburg**. Die Bauarbeiten beginnen im Frühjahr 2027. Umweltverbände begrüßen die Pläne, während einige Geschäftsleute den Verlust von Parkplätzen kritisieren.

Factually correct and complete information

Faithfulness 6/7,
Coverage 6/7

- Factual error detected but only 1 pt. reduced
- Despite the factual error, summary B was preferred
    - So incompleteness of summary A was penalized higher
- Step 2: adding a numerical error to summary B
    - Source article: 50 km
    - Summary B (incorrect): 150 km
- Result on next slide →

Example

Berlin plant Ausbau des Fahrradwegenetzes

Die Berliner Senatsverwaltung für Verkehr hat angekündigt, das Fahrradwegenetz der Hauptstadt in den kommenden zwei Jahren deutlich auszubauen. Bis Ende 2028 sollen insgesamt 50 Kilometer neue, geschützte Radwege entstehen. Für das Projekt stellt die Stadt rund 25 Millionen Euro bereit.

Der Ausbau konzentriert sich zunächst auf die Bezirke Mitte, Friedrichshain-Kreuzberg und Neukölln. Ziel der Maßnahmen ist es, die Verkehrssicherheit für Radfahrerinnen und Radfahrer zu verbessern und den Autoverkehr langfristig zu reduzieren. Nach Angaben der Senatsverwaltung sollen die ersten Bauarbeiten im Frühjahr 2027 beginnen.

Während Umweltverbände die Pläne begrüßen, äußern einige Geschäftsleute Bedenken hinsichtlich des Wegfalls von Parkplätzen.

Summary A :

Die Berliner Senatsverwaltung plant den Bau von 50 Kilometern Die Berliner Senatsverwaltung plant den Bau von 50 Kilometern neuen geschützten Radwegen bis Ende 2028. Ziel des Projekts ist es, die Verkehrssicherheit für Radfahrerinnen und Radfahrer zu verbessern.

Factually correct and missing information

Faithfulness 7/7,
Coverage 4/7

Summary B:

Die Berliner Senatsverwaltung plant den Bau von 50 Kilometern neuen geschützten Radwegen bis Ende 2028. Dafür stehen 25 Millionen Euro zur Verfügung. Der Ausbau betrifft Mitte, Friedrichshain-Kreuzberg und **Charlottenburg**. Die Bauarbeiten beginnen im Frühjahr 2027. Umweltverbände begrüßen die Pläne, während einige Geschäftsleute den Verlust von Parkplätzen kritisieren.

Factually correct and complete information

Faithfulness 3/7,
Coverage 6/7

- Factual error detected, and penalized heavily by reducing 4 points
- Despite the factual error, summary B was preferred
    - So, the incompleteness of summary A was penalized higher
- Hence it is unclear how LLMs assess severity of errors
    - Different error types receive different penalties.
    - How closely do these penalties reflect human judgments?
    - How should factual errors be weighed against missing information?
    - Can we make LLM preferences more consistent with human judgments?

Technische Universität Berlin

Can We Trust LLM-Based Evaluations?

A judge may produce plausible decisions, but are these decisions reliable, consistent, and robust?

Our Approach: Systematic Robustness Testing

Quality & Usability Lab

Related Work

How Reliable Are LLM Judges?

1. LLMs as Evaluators — Zheng et al. (2023)

- LLMs can compare generated responses and approximate human preferences.
- However, judgments can be influenced by position and response length.

2. Biases in LLM Evaluation — Ye et al. (2025)

- LLM judges exhibit different types of systematic biases.
- Controlled experiments can help identify and measure these biases.

3. Adversarial Robustness — Raina et al. (2024)

- Carefully constructed inputs can manipulate LLM evaluation decisions.
- This raises questions about the reliability of automated evaluation.

Open question for our project: How stable are LLM preferences when we systematically manipulate the texts being compared?

Emerging Research Questions:

- **RQ1 — Error Sensitivity**
  - How do LLM judges detect and penalize different types and severities of factual errors?
- **RQ2 —** Reliability and Consistency
  - When do LLM judges produce unreliable or inconsistent preferences, particularly when faithfulness and coverage conflict?
- RQ3 — Mitigating Evaluation Failures
  - How can prompting and evaluation strategies improve the reliability of LLM judges' ratings and pairwise preferences?

Tasks - Project Setup & Inputs

Technische Universität Berlin

Link to the dataset: https://git.tu-berlin.de/neha.deshpande/annotated_news_summaries/-/tree/main?ref_type=heads

- Use the articles in this data
- Also from https://huggingface.co/datasets/mteb/summeval (English data)

Quality & Usability Lab

Tasks - Robustness Testing Pipeline

Technische Universität Berlin

Human-Annotated Dataset

↓

1. Baseline Evaluation

Generate baseline summaries using the data mentioned in previous slide; verify that they are factually correct and complete (the prompt can be discussed)

2. Error Taxonomy and Severity Annotation

Create controlled factual errors and coverage omissions at different severity levels; validate error types and severity levels.

3. Run Controlled Experiments

Evaluate original and modified summary pairs using 2-3 LLMs (prompts on the next two slides)

4. Analyse results and mitigate evaluation failures

Measure preference stability, severity sensitivity, quality trade-offs, and cross-model differences, and techniques for mitigation: step-by-step prompting, etc.

↓

RQ1	**RQ2**	**RQ3**
Error Sensitivity	Preference Robustness	Generalization

Quality & Usability Lab

Prompt 1: simple

Technische Universität Berlin

Sie sind ein kritischer Redakteur und erhalten einen Artikel sowie zwei Zusammenfassungen dieses Artikels. Wählen Sie die bessere Zusammenfassung nach Ihrem eigenen Urteil aus.

Artikel:
{article}

Zusammenfassung A:
{summary_a}

Zusammenfassung B:
{summary_b}

Bitte geben Sie Ihre bevorzugte Zusammenfassung mit einem einzelnen Buchstaben "A" oder "B" an. Weitere Zeichen oder Erläuterungen sind nicht erforderlich.

Ihre Antwort: <A/B>

Quality & Usability Lab

Prompt 2: detailed and defined

Sie sind ein/e Zusammenfassungsprüfer/in und erhalten einen Artikel sowie zwei Zusammenfassungen dieses Artikels. Wählen Sie die bessere Zusammenfassung nach Ihrem eigenen Urteil aus.

Berücksichtigen Sie bei der Auswahl insbesondere diese beiden Dimensionen:

Inhaltsabdeckung: Die Zusammenfassung erfasst die wesentlichen Informationen des Originalartikels aus der Perspektive eines Nachrichtenlesers (sodass der Originalartikel nicht unbedingt benötigt wird).

Getreuheit: Die Zusammenfassung sollte inhaltlich korrekt und sprachlich verständlich sein. Sie darf keine erfundenen Details enthalten, die nicht in der Quelle vorkommen.

Bevorzugen Sie die Zusammenfassung, die beide Dimensionen insgesamt besser erfüllt. Eine höhere Inhaltsabdeckung soll erfundene oder widersprüchliche Aussagen nicht rechtfertigen.

Artikel:
{article}

Zusammenfassung A:
{summary_a}

Zusammenfassung B:
{summary_b}

Bitte geben Sie Ihre bevorzugte Zusammenfassung mit einem einzelnen Buchstaben "A" oder "B" an. Weitere Zeichen oder Erläuterungen sind nicht erforderlich.

Ihre Antwort: <A/B>

Technische Universität Berlin

Quality & Usability Lab

Project Timeline (Oct 2026 – Feb 2027)

Technische Universität Berlin

Phase 1 — Introduction & Research Design

14 Oct	Kick-off: Introduction, project goals, and organization
14–21 Oct	Literature review: Existing robustness evaluation methods, go through the dataset
21–28 Oct	Select data to be tested

Phase 2 — Experimental Setup & Pilot Studies

28 Oct – 4 Nov	Create an error taxonomy for coverage and factual errors at different severity levels
4–11 Nov	Inject errors – factual errors by types (use [1]) and coverage errors like deletion of content, as shown in the example previously in the presentation
11–18 Nov	Rate the summaries on factuality based on severity – rubric for rating to be provided, create final error-injected data for testing
18–25 Nov	
25 Nov – 9 Dec	Prepare midterm presentation

9 Dec: Practice presentation
10 Dec: Midterm presentation — 10 minutes + 5 minutes Q&A
Expected: Research questions, related work, methodology, and preliminary results

Quality & Usability Lab

1. https://arxiv.org/abs/2104.13346

Project Timeline (Oct 2026 – Feb 2027)

Technische Universität Berlin

Phase 3 — Main Experiments & Analysis

10–16 Dec	Run error injected data on 2-3 LLMs
6–13 Jan	Evaluate LLM output against dataset validated by you
13–20 Jan	Analyse failures and develop techniques for mitigation: alternate prompts, step-by-step approaches, etc.
20–27 Jan	Test again and see if there is improvement
27 Jan – 3 Feb	Consolidate findings, identify limitations, and prepare final presentation

3th Feb: Practice presentation
4th Feb: Final presentation — 20 minutes + 5 minutes Q&A
25 Feb: Final report submission via email

Quality & Usability Lab

Learning Goals

What Will You Learn?

- How LLM-based evaluation systems work and how they are used in NLP research
- How to design controlled robustness experiments
- How to measure stability, agreement, and ranking consistency
- How prompt design influences model behavior
- How to critically assess AI systems

Tools and Skills needed

- **Tools:** Python, Hugging Face Transformers, Basic Prompting Skills
- **Skills:**
  - Interest in NLP
  - Transformers/LLMs

Important Links for Related Work

Technische Universität Berlin

- Judging the Judges: Evaluating Alignment and Vulnerabilities in LLMs-as-Judges
- JudgeBench: A Benchmark for Evaluating LLM-Based Judges
- Adversarial Attacks on LLM-as-a-Judge Systems: Insights from Prompt Injections
- Is LLM-as-a-Judge Robust? Investigating Universal Adversarial Attacks on Zero-shot LLM Assessment

Quality & Usability Lab